


Optimisation

Chapitre 2


Algorithmes d'optimisation numérique



Master IASD

Tarik AMTOUT

tarik.amtout@gmail.com



Formulation d'un problème d'optimisation


La forme standard d'un problème d'optimisation continue est la suivante.

$$\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}) \quad \text{sous} \quad \begin{cases} c_E(\mathbf{x}) = 0 \\ c_I(\mathbf{x}) \leq 0 \end{cases} \quad (1.1)$$

Le vecteur $\mathbf{x} \in \mathbb{R}^n$ représente les n variables ou paramètres du problème.

$$\mathbf{x} = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} \in \mathbb{R}^n$$

La fonction à minimiser $f : \mathbb{R}^n \rightarrow \mathbb{R}$ est appelée coût ou objectif ou encore critère.



La fonction $c_E : \mathbb{R}^n \rightarrow \mathbb{R}^p$ représente un vecteur de p contraintes d'égalité.


$$c_E(x) = \begin{pmatrix} c_{E1}(x) \\ \vdots \\ c_{Ep}(x) \end{pmatrix} \quad \text{avec } c_{Ej} : \mathbb{R}^n \rightarrow \mathbb{R}$$

La fonction $c_I : \mathbb{R}^n \rightarrow \mathbb{R}^q$ représente un vecteur de q contraintes d'inégalité.

$$c_I(x) = \begin{pmatrix} c_{I1}(x) \\ \vdots \\ c_{Iq}(x) \end{pmatrix} \quad \text{avec } c_{Ij} : \mathbb{R}^n \rightarrow \mathbb{R}$$

Les contraintes c_E et c_I sont regroupées dans le vecteur c de dimension $m = p + q$.


$$c(x) = \begin{pmatrix} c_E(x) \\ c_I(x) \end{pmatrix} \in \mathbb{R}^m$$



Tout problème d'optimisation peut se mettre sous la forme standard (1.1) en utilisant les transformations suivantes.


Maximisation/minimisation : $\max_x f(x) \Leftrightarrow \min_x -f(x)$

Contrainte supérieur / inférieur : $c(x) \geq 0 \Leftrightarrow -c(x) \leq 0$



Hypothèses :

- Continuité :
 - Fonctions continues de variables réelles
 - Optimisation continue
 - ≠ Optimisation combinatoire, Programmation en nombres entiers
- Différentiabilité :
 - Fonctions différentiables
 - **Méthodes à base de gradient**
 - ≠ Méthodes sans dérivées
- Déterminisme :
 - Les données du problème sont parfaitement connues
 - ≠ Optimisation stochastique




Norme

Norme vectorielle sur \mathbb{R}^n


- Fonction $\| \cdot \| : \mathbb{R}^n \rightarrow \mathbb{R}$ vérifiant

$$\begin{cases} \|x\| \geq 0 \\ \|x\| = 0 \Leftrightarrow x = 0 \\ \|x + y\| \leq \|x\| + \|y\| \\ \|\alpha x\| = |\alpha| \|x\| \end{cases}$$
- Norme p : $\|x\|_p = \sqrt[p]{\sum_{i=1}^n |x_i|^p}$
- Norme ∞** : $\|x\|_\infty = \max_{i=1, \dots, n} |x_i|$
- Norme 2** = norme euclidienne



Norme matricielle

- Norme induite sur $\mathbb{R}^{m \times n}$ par la norme vectorielle $\| \cdot \|$
- Fonction $\| \cdot \|_{m \times n} : \mathbb{R}^{m \times n} \rightarrow \mathbb{R}$ définie par $\|A\|_{m \times n} = \max_{x \in \mathbb{R}^n, x \neq 0} \frac{\|Ax\|}{\|x\|}$




Suite

Suite dans \mathbb{R}^n

- Suite : $\{x_k, k=0,1,2,\dots\} = \{x_0, x_1, x_2, \dots, x_n, \dots\}$
- Limite : $\lim_{k \rightarrow \infty} x_k = x^* \Leftrightarrow \lim_{k \rightarrow \infty} \|x_k - x^*\|$

Vitesse de convergence

- Convergence linéaire : $\|x_{k+1} - x^*\| \leq c \|x_k - x^*\|$ avec $0 \leq c < 1$
→ lent à partir d'un certain rang k_0
- Convergence superlinéaire : $\|x_{k+1} - x^*\| \leq c_k \|x_k - x^*\|$ avec $\lim_{k \rightarrow \infty} c_k = 0$
→ bonne à partir d'un certain rang k_0
- Convergence d'ordre p : $\|x_{k+1} - x^*\| \leq c \|x_k - x^*\|^p$ avec $0 \leq c < 1$
à partir d'un certain rang k_0
- **Convergence quadratique** si $p=2$
→ rapide



Différentiabilité


Différentiabilité ordre 1

f fonction continue de \mathbb{R}^n dans \mathbb{R}

Dérivée partielle

Dérivée partielle de f en x par rapport à x_i :
si la limite existe

$$f_{x_i}(x) = \frac{\partial f(x)}{\partial x_i} = \lim_{s \rightarrow 0} \frac{f(x_1, \dots, x_i + s, \dots, x_n) - f(x_1, \dots, x_i, \dots, x_n)}{s}$$



Gradient

Gradient

Gradient de f en x : $g(x) = \nabla f(x)$

$$g(x) : \mathbb{R}^n \rightarrow \mathbb{R}^n$$

si toutes les dérivées partielles existent

$$g(x) = \nabla f = \begin{pmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_n} \end{pmatrix}$$

Dérivée directionnelle

Dérivée directionnelle de f en x dans la direction $d \in \mathbb{R}^n$:

si la limite existe


(dérivée directionnelle = produit scalaire avec le gradient)

$$f_d(x) = \lim_{s \rightarrow 0} \frac{f(x + sd) - f(x)}{s}$$

$$\Rightarrow f_d(x) = g(x)^T d$$

Fonction différentiable

f différentiable en $x \Leftrightarrow f$ admet une dérivée directionnelle pour tout $d \in \mathbb{R}^n$



Hessien

Différentiabilité ordre 2


f fonction deux fois différentiable de \mathbb{R}^n dans \mathbb{R}

Hessien

Hessien de f en x : $H(x) = \nabla^2 f(x)$

$H(x) : \mathbb{R}^n \rightarrow \mathbb{R}^{n \times n}$

$$H(x) = \left(\frac{\partial^2 f(x)}{\partial x_i \partial x_j} \right)_{i,j=1,\dots,n} = \begin{pmatrix} \frac{\partial^2 f(x)}{\partial^2 x_1} & \dots & \frac{\partial^2 f(x)}{\partial x_1 \partial x_n} \\ \dots & \dots & \dots \\ \frac{\partial^2 f(x)}{\partial x_n \partial x_1} & \dots & \frac{\partial^2 f(x)}{\partial^2 x_n} \end{pmatrix}$$



Jacobien

Matrice gradient


c fonction continue de \mathbb{R}^n dans \mathbb{R}^m

Gradient de c en x : $\nabla c(x) : \mathbb{R}^n \rightarrow \mathbb{R}^{n \times m}$

$$\nabla c(x) = (\nabla c_1(x), \dots, \nabla c_m(x)) = \left(\frac{\partial c_j(x)}{\partial x_i} \right)_{\substack{i=1, \dots, n \\ j=1, \dots, m}} = \begin{pmatrix} \frac{\partial c_1(x)}{\partial x_1} & \dots & \frac{\partial c_m(x)}{\partial x_1} \\ \dots & \dots & \dots \\ \frac{\partial c_1(x)}{\partial x_n} & \dots & \frac{\partial c_m(x)}{\partial x_n} \end{pmatrix}$$

Matrice jacobienne (« jacobien » = déterminant de J_c)

$$J_c(x) = \nabla c(x)^T = \begin{pmatrix} \nabla c_1(x)^T \\ \dots \\ \nabla c_m(x)^T \end{pmatrix} = \left(\frac{\partial c_i(x)}{\partial x_j} \right)_{\substack{i=1, \dots, n \\ j=1, \dots, m}} = \begin{pmatrix} \frac{\partial c_1(x)}{\partial x_1} & \dots & \frac{\partial c_1(x)}{\partial x_n} \\ \dots & \dots & \dots \\ \frac{\partial c_m(x)}{\partial x_1} & \dots & \frac{\partial c_m(x)}{\partial x_n} \end{pmatrix}$$



Méthodes de Newton

- La méthode de Newton sert à résoudre numériquement un système d'équations non linéaires. Elle est à la base de la majorité des algorithmes d'optimisation.

Considérons un système de n équations non linéaires à n inconnues.


$$g(x) = 0 \quad \text{avec} \quad g : x \in \mathbb{R}^n \mapsto g(x) \in \mathbb{R}^n$$

La fonction g est supposée différentiable. Écrivons son développement de Taylor à l'ordre 1 en un point x_0 .

$$g(x) = g(x_0) + \nabla g(x_0)^T (x - x_0) + o(\|x - x_0\|)$$

En approximant au voisinage de x_0 la fonction g par la fonction linéaire \hat{g}_0 :

$$\hat{g}_0(x) \stackrel{\text{def}}{=} g(x_0) + G_0 (x - x_0) \quad \text{avec} \quad G_0 = \nabla g(x_0)^T$$



et en résolvant le système linéaire :

$$\hat{g}_0(x) = 0$$


on obtient le point x_1 :

$$x_1 = x_0 - G_0^{-1}g(x_0)$$


Les itérations de Newton sont définies par :

$$x_{k+1} = x_k - G_k^{-1}g(x_k) \quad \text{avec} \quad G_k = \nabla g(x_k)^T$$

La méthode de Newton consiste à itérer le processus jusqu'à obtenir une solution satisfaisante.




Principe de la méthode de Newton



En dimension 1, la méthode de Newton est aussi appelée méthode de la tangente et est donnée par :

$$x_{k+1} = x_k - \frac{g(x_k)}{g'(x_k)}$$




Exemples

Équation 1 : Résoudre $g(x) = x^2 - 1 = 0$.

Le Tableau 3-1 montre les itérations de Newton à partir de $x_0 = 4$.

La méthode converge vers la solution $x^* = 1$

Itération	x_k	$g(x_k)$	$g'(x_k)$
0	4,000000000	1,5E+01	8,0000
1	2,125000000	3,5E+00	4,2500
2	1,29779412	6,8E-01	2,5956
3	1,03416618	6,9E-02	2,0683
4	1,00056438	1,1E-03	2,0011
5	1,00000016	3,2E-07	2,0000
6	1,00000000	2,5E-14	2,0000




Équation 2 : Résoudre $g(x) = (x - 1)^2 = 0$.

Le Tableau montre les itérations de Newton à partir de $x_0 = 4$.

La méthode converge vers la solution $x^* = 1$

Itération	x_k	$g(x_k)$	$g'(x_k)$
0	4,00000000	9,0E+00	6,0000
1	2,50000000	2,3E+00	3,0000
2	1,75000000	5,6E-01	1,5000
3	1,37500000	1,4E-01	0,7500
4	1,18750000	3,5E-02	0,3750
5	1,09375000	8,8E-03	0,1875
6	1,04687500	2,2E-03	0,0938
7	1,02343750	5,5E-04	0,0469
8	1,01171875	1,4E-04	0,0234
9	1,00585938	3,4E-05	0,0117
10	1,00292969	8,6E-06	0,0059
15	1,00009155	8,4E-09	0,0002
20	1,00000286	8,2E-12	0,0000



Équation 3 : Résoudre $g(x) = \text{Arc tan } x = 0$.

Les deux tableaux montre les itérations de Newton à partir de $x_0 = 1,3$ ou $x_0 = 1,5$.


Itération	x_k	$g(x_k)$	$g'(x_k)$
0	1,300	0,915	0,372
1	-1,162	-0,860	0,426
2	0,859	0,710	0,575
3	-0,374	-0,358	0,877
4	0,034	0,034	0,999
5	0,000	0,000	1,000
6	0,000	0,000	1,000

Converge $x_0 = 1,3$

Itération	x_k	$g(x_k)$	$g'(x_k)$
0	1,500	0,983	0,308
1	-1,694	-1,038	0,258
2	2,321	1,164	0,157
3	-5,114	-1,378	0,037
4	32,296	1,540	0,001
5	-1575,317	-1,570	0,000
6	3894976,008	1,571	0,000

Diverge pour $x_0 = 1,5$

Ces exemples en dimension 1 montrent que la convergence de la méthode de Newton n'est pas garantie



Problème de minimisation

Considérons à présent un problème de minimisation sans contraintes.

Problème sans contrainte

$$\min_{x \in \mathbb{R}^n} f(x) \quad \rightarrow \quad \begin{array}{l} \text{gradient : } g(x) = \nabla f(x) \\ \text{hessien : } H(x) = \nabla^2 f(x) \end{array}$$


Condition nécessaire de minimum local

$$x^* \text{ minimum local} \Rightarrow \begin{cases} g(x^*) = 0 \\ H(x^*) \geq 0 \end{cases} \quad (\text{hessien semi-défini positif})$$


Recherche des points stationnaires

Application de la méthode de Newton au système d'équations non linéaires : $\boxed{g(x) = 0}$

$$\text{Modèle linéaire de } g \text{ en } x_k : \hat{g}_k(x) = g(x_k) + G_k(x - x_k) \text{ avec } \begin{cases} g(x_k) = \nabla f(x_k) \\ G_k = \nabla g(x_k)^T = \nabla^2 f(x_k) = H_k \end{cases}$$



- Méthode de **Newton** : $G = H \rightarrow$ calcul explicite du hessien à chaque itération
- Méthode de **quasi-Newton** : $G =$ approximation de H
construite à partir des itérations précédentes
sans calcul explicite du hessien



Méthode de Newton


Modèle linéaire de $g=\nabla f$ en x_k

$$\hat{g}_k(x) = g(x_k) + G_k(x - x_k) \quad \text{avec} \quad \begin{cases} g(x_k) = \nabla f(x_k) \\ G_k = \nabla g(x_k)^T = \nabla^2 f(x_k) = H_k \end{cases}$$

- Itération : $x_{k+1} = x_k - \nabla^2 f(x_k)^{-1} \nabla f(x_k)$ → équations de Newton
- Condition d'arrêt : $\|\nabla f(x_k)\| \leq \varepsilon$

Difficultés

- Calcul explicite et inversion du hessien $\nabla^2 f(x_k)$ à chaque itération → coûteux
- Convergence non garantie même près de la solution
→ mêmes difficultés que pour la résolution d'équations
- 1^{ère} condition nécessaire de minimum : $\nabla f(x^*)=0$
→ point stationnaire $x^* = \text{minimum local, maximum local ou point selle}$
→ 2^{ème} condition nécessaire de minimum à vérifier : $\nabla^2 f(x^*) \geq 0$



Modèle quadratique de f en x_k

- Développement de Taylor à l'ordre 2 de f en x_k


$$f(x) = f(x_k) + \nabla f(x_k)^T (x - x_k) + \frac{1}{2} (x - x_k)^T \nabla^2 f(x_k) (x - x_k) + o(\|x - x_k\|^2)$$


- Modèle quadratique en x_k

$$\hat{f}_k(x) = f_k(x_k) + g_k^T (x - x_k) + \frac{1}{2} (x - x_k)^T H_k (x - x_k)$$

- Lien entre le modèle de f et le modèle de $g = \nabla f$

$$\nabla \hat{f}_k(x) = g_k + H_k (x - x_k) = \hat{g}_k(x)$$





Minimisation du modèle de f en x_k

- Conditions suffisantes de minimum local : $\min_{x \in \mathbb{R}^n} \hat{f}_k(x) \Leftrightarrow \begin{cases} \nabla \hat{f}_k(x^*) = \hat{g}_k(x^*) = 0 \\ \nabla^2 \hat{f}_k(x^*) = H_k > 0 \end{cases}$
- Si le hessien de f en x_k est défini positif : $\nabla^2 f(x_k) > 0$
Minimisation du modèle quadratique de f en x_k
 \Leftrightarrow Méthode de Newton en x_k pour résoudre $\nabla f(x)=0$
- Sinon la méthode de Newton n'est pas directement applicable pour une minimisation

