C4.5 (avec le gain d'information, cette implementation est juste pour montrer que l'utilisation du gain d'information a donné des resulats plus efficace que l'utilisation du rapport de gain) - Ce model implementé a l'aide des notions de la programmation orientée objet, puisque je vois que c'est plus facile de comprendre le code et de le modifier (la programation fonctionnelle pour implementer ce type de model rend les choses plus compliquées)

## Import des bibliothèques

```
import numpy as np
import seaborn
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score
```

### Données

```
col_names = ['sepal length', 'sepal width', 'petal length', 'petal
width', 'type']
data = seaborn.load_dataset("iris", skiprows=1, header=None,
names=col_names)
```

### Class noeud

```
class Node():
    def __init__(self, feature_index=None, threshold=None, left=None,
right=None, info_gain=None, value=None):
    # constructeur

# pour les noeuds de décision
    self.feature_index = feature_index
    self.threshold = threshold
```

```
self.left = left
self.right = right
self.info_gain = info_gain

# pour les noeuds feuilles
self.value = value
```

### Class Arbre de decision

```
class DecisionTreeClassifier():
    def init (self, min samples split=2, max depth=2):
        # constructeur
        # inisialisation de la racine de l'arbre
        self.root = None
        self.dic = {}
        # conditions d'arret
        self.min samples split = min samples split
        self.max depth = max depth
    def build tree(self, dataset, curr depth=0):
        # fonction récursive pour construire l'arbre de decision
        X, Y = dataset[:,:-1], dataset[:,-1]
        num samples, num features = np.shape(X)
        # fractionner jusqu'à ce que les conditions d'arrêt soient
vrai
        if num samples>=self.min samples split and
curr depth<=self.max depth:</pre>
            # trouver la meilleure répartition
            best split = self.get best split(dataset, num samples,
num features)
            # vérifier si le gain d'information est positif
            if best split["info gain"]>0:
                # récurrence gauche
                left subtree =
self.build tree(best split["dataset left"], curr depth+1)
                # récurrence droite
                right subtree =
self.build tree(best split["dataset right"], curr depth+1)
                self.dic[best_split["feature_index"]] =
best split["threshold"]
                # retourner le noeud de décision
                return Node(best split["feature index"],
best split["threshold"],
                            left_subtree, right_subtree,
best split["info gain"])
```

```
# Calculer le noeud feuille
        leaf value = self.calculate leaf value(Y)
        # retourner le noeud feuille
        return Node(value=leaf value)
    def get best split(self, dataset, num samples, num features):
        # pour trouver la meilleure répartition
        # dictionnaire pour stocker la meilleure part
        best split = {}
        max info gain = -float("inf")
        # boucle sur l'ensemble des caractéristiques
        for feature index in range(num features):
            feature values = dataset[:, feature index]
            possible thresholds = np.unique(feature values)
            # boucler sur toutes les valeurs des caractéristiques
présentes dans les données
            for threshold in possible thresholds:
                # obtenir la répartition actuelle
                dataset left, dataset right = self.split(dataset,
feature index, threshold)
                # vérifier si les enfants ne sont pas nuls
                if len(dataset left)>0 and len(dataset right)>0:
                    y, left_y, right_y = dataset[:, -1],
dataset_left[:, -1], dataset_right[:, -1]
                    # calculer le gain d'information
                    curr info gain = self.information_gain(y, left_y,
right y, "gini")
                    # mettre à jour la meilleure répartition si
nécessaire
                    if curr info gain>max info gain:
                        best split["feature index"] = feature index
                        best split["threshold"] = threshold
                        best split["dataset left"] = dataset left
                        best split["dataset right"] = dataset right
                        best split["info gain"] = curr info gain
                        max info gain = curr info gain
        # retour meilleure répartition
        return best split
    def split(self, dataset, feature index, threshold):
        # pour diviser les données
        dataset left = np.array([row for row in dataset if
row[feature index]<=threshold])</pre>
        dataset right = np.array([row for row in dataset if
row[feature index]>threshold])
        return dataset left, dataset right
```

```
def gain ratio(self, parent, l child, r child, mode="entropy"):
        # fonction permettant de calculer le rapport de gain
d'information
        weight_l = len(l_child) / len(parent)
        weight_r = len(r child) / len(parent)
        if mode=="gini":
            gain = self.gini index(parent) -
(weight l*self.gini index(l child) +
weight r*self.gini index(r child))
        else:
            gain = self.entropy(parent) -
(weight l*self.entropy(l child) + weight r*self.entropy(r child))
        if weight l != 0 and weight l != 0:
            info inter = - weight l*np.log2(weight l) -
weight r*np.log2(weight l)
        return gain/info inter if info inter else 0
    def information gain(self, parent, l child, r child,
mode="entropy"):
        # fonction permettant de calculer le gain d'information
        weight l = len(l child) / len(parent)
        weight_r = len(r_child) / len(parent)
        if mode=="gini":
            gain = self.gini index(parent) -
(weight l*self.gini index(l child) +
weight r*self.gini index(r child))
        else:
            gain = self.entropy(parent) -
(weight l*self.entropy(l child) + weight r*self.entropy(r child))
        return gain
    def entropy(self, y):
        # fonction pour calculer l'entropie
        class_labels = np.unique(y)
        entropy = 0
        for cls in class labels:
            p cls = len(y[y == cls]) / len(y)
            entropy += -p cls * np.log2(p cls)
        return entropy
    def gini index(self, y):
        # Fonction de calcul de l'indice de Gini
```

```
class labels = np.unique(v)
        qini = 0
        for cls in class labels:
            p cls = len(y[y == cls]) / len(y)
            gini += p cls**2
        return 1 - gini
    def calculate leaf value(self, Y):
        # pour calculer le nœud de la feuille
        Y = list(Y)
        return max(Y, key=Y.count)
    def print tree(self, tree=None, indent=" "):
        # pour imprimer l'arbre
        if not tree:
            tree = self.root
        if tree.value is not None:
            print(tree.value)
        else:
            print(col names[tree.feature index], "<=", tree.threshold,</pre>
" | gain ratio: ", tree.info gain)
            print("%sleft(true):" % (indent), end="")
            self.print tree(tree.left, indent + indent)
            print("%sright(false):" % (indent), end="")
            self.print tree(tree.right, indent + indent)
    def tree to dict(self, tree=None):
        # pour transformer l'arbre en dictionnaire
        if tree is None:
            tree = self.root
        if tree.value is not None:
            return tree.value
        feature name = col names[tree.feature index] if
tree.feature index is not None else None
        left tree = self.tree to dict(tree.left)
        right_tree = self.tree_to_dict(tree.right)
        if feature name is not None:
            return {feature_name: {f'<={tree.threshold}': {'left</pre>
(true)': left tree, 'right (false)': right tree}}}
        else:
```

```
# Il s'agit du nœud feuille
        return tree.value
def fit(self, X, Y):
    # pour former l'arbre
    dataset = np.concatenate((X, Y), axis=1)
    self.root = self.build tree(dataset)
    self.dic = self.tree to dict()
def predict(self, X):
    # fonction de prédiction d'un nouvel ensemble de données
    preditions = [self.make prediction(x, self.root) for x in X]
    return preditions
def make prediction(self, x, tree):
    # pour prédire un seul point de données
    if tree.value!=None: return tree.value
    feature val = x[tree.feature index]
    if feature val<=tree.threshold:</pre>
        return self.make prediction(x, tree.left)
        return self.make prediction(x, tree.right)
```

# Split en données Train et Test

```
X = data.iloc[:, :-1].values
Y = data.iloc[:, -1].values.reshape(-1,1)
X_train, X_test, Y_train, Y_test = train_test_split(X, Y,
test_size=.2, random_state=41)
```

### Fit le model au données Train

## Test du model pour avoir un metric d'evaluation

# Ici j'est utilisé toutes les données pour avoir un arbre plus complet

```
## Fit the model
classifier2 = DecisionTreeClassifier(min samples split=3, max depth=3)
classifier2.fit(X, Y)
classifier2.print tree()
left(true):setosa
 right(false):petal width <= 1.7 | gain ratio: 0.38969404186795487
 left(true):petal length <= 4.9 | gain ratio: 0.08239026063100136
   left(true):petal width <= 1.6 | gain ratio: 0.040798611111111116
      left(true):versicolor
      right(false):virginica
   left(true):virginica
      right(false):versicolor
 right(false):petal length <= 4.8 | gain ratio:
0.013547574039067499
   left(true):versicolor
      right(false):virginica
   right(false):virginica
print(classifier2.dic)
{'petal length': {'<=1.9': {'left (true)': 'setosa', 'right (false)':</pre>
{'petal width': {'<=1.7': {'left (true)': {'petal length': {'<=4.9':
{'left (true)': {'petal width': {'<=1.6': {'left (true)':
```

```
'versicolor', 'right (false)': 'virginica'}}}, 'right (false)':
{'petal width': {'<=1.5': {'left (true)': 'virginica', 'right
(false)': 'versicolor'}}}}}, 'right (false)': {'petal length':
{'<=4.8': {'left (true)': {'sepal length': {'<=5.9': {'left (true)':
'versicolor', 'right (false)': 'virginica'}}}, 'right (false)':
'virginica'}}}}}</pre>
```